

---

# Projet Filtrage et Estimation

---

## Rapport

Mehdi Khabouze

Décembre 2024

# Table des matières

<b>1</b>	<b>Introduction</b>	<b>2</b>
<b>2</b>	<b>Extraction d'une signature caractérisant la dépendance long terme</b>	<b>2</b>
2.1	Introduction . . . . .	2
2.2	Préambule . . . . .	2
2.2.1	Fonction d'autocorrélation . . . . .	2
2.2.2	Spectre de puissance . . . . .	3
2.2.3	Périodogrammes . . . . .	4
2.2.4	Corrélogramme . . . . .	4
2.2.5	Bruitage de signaux . . . . .	5
2.2.6	Représentation temporelle et spectrogramme des signaux . . . . .	6
2.3	DFA . . . . .	7
2.3.1	Étape 1 : Centrage et intégration du signal . . . . .	7
2.3.2	Étape 2 : Découpage en segments et estimation de la tendance locale . .	7
2.3.3	Étape 3 : Expression de $F_2(N)$ . . . . .	7
2.3.4	Étape 4 : Calcul de H . . . . .	8
2.4	Application du DFA sur les signaux de Weierstrass . . . . .	8
2.5	Application sur le signal de parole . . . . .	8
2.5.1	Représentations Graphiques . . . . .	9
2.6	Application du DFA sur les signaux de bruit blanc et bruit rose . . . . .	13
2.7	Analyse des résultats du DFA sur les signaux vocaux RAVDESS . . . . .	13
2.7.1	Classification selon l'émotion . . . . .	13
2.7.2	Classification selon le genre (H/F) . . . . .	14
2.8	Application de la DFA sur les signaux ECG . . . . .	15
<b>3</b>	<b>Utilisation d'un grand modèle de langage par le biais d'un chatbot</b>	<b>17</b>
3.1	Stratégie et Évaluation du Prompting . . . . .	17
<b>4</b>	<b>Conclusion</b>	<b>22</b>

# 1 Introduction

Le traitement du signal est une discipline essentielle appliquée à divers domaines tels que l’audio, les signaux biomédicaux et les systèmes de communication. Ce projet se concentre sur l’analyse des signaux de parole en utilisant la méthode DFA (Detrended Fluctuation Analysis) pour évaluer la dépendance à long terme et améliorer la qualité des signaux altérés par du bruit. En appliquant la DFA à des enregistrements vocaux et des signaux physiologiques, l’objectif est de développer des techniques robustes de classification et de débruitage, renforçant ainsi les compétences en traitement numérique du signal acquises durant les études.

## 2 Extraction d’une signature caractérisant la dépendance long terme

### 2.1 Introduction

Dans cette partie du projet, nous utilisons la méthode DFA (Detrended Fluctuation Analysis) pour analyser des signaux vocaux et physiologiques. L’objectif est d’évaluer la dépendance à long terme de ces signaux grâce à l’exposant de Hurst ( $H$ ). En appliquant cette méthode à des signaux simulés et à des enregistrements vocaux de la base RAVDESS, nous cherchons à vérifier si le DFA peut aider à différencier des émotions ou des caractéristiques spécifiques des signaux. Cette approche pourrait avoir des applications intéressantes, notamment pour la classification de signaux physiologiques.

### 2.2 Préambule

Dans ce qui suit, l’analyse porte sur les propriétés du bruit blanc, son autocorrélation et son spectre, avec une comparaison des périodogrammes de Daniell, Bartlett et Welch. Un traitement est également réalisé pour ajouter du bruit à des signaux, permettant d’étudier les impacts temporels et spectraux.

#### 2.2.1 Fonction d’autocorrélation

La fonction d’autocorrélation théorique du bruit blanc est une impulsion de Dirac centrée en zéro. Cela montre l’absence de corrélation entre les échantillons successifs du signal, ce qui caractérise un processus purement aléatoire. La figure 1 illustre cette propriété : la partie supérieure montre l’autocorrélation estimée à partir de la réalisation du bruit blanc, tandis que la partie inférieure représente l’autocorrélation théorique. On observe que l’estimation converge vers la théorie, mais elle est affectée par des fluctuations dues à la finitude de l’échantillon.

L’estimation de l’autocorrélation est réalisée à l’aide de la fonction `xcorr` de MATLAB en mode biaisé, défini par :

$$R_{xx}(\tau) = \frac{1}{N - |\tau|} \sum_{n=0}^{N-|\tau|-1} x[n] \cdot x[n + \tau]. \quad (1)$$

Cet estimateur suppose un signal stationnaire au second ordre et une taille suffisante pour une estimation précise.

Les observations ci-dessus mettent en évidence l’importance des conditions d’estimation dans la validation des propriétés théoriques d’un processus aléatoire.




FIGURE 1 – Fonction d'autocorrélation estimée (haut) et théorique (bas) du bruit blanc.

### 2.2.2 Spectre de puissance

Le spectre de puissance d'une réalisation de bruit blanc montre des variations autour d'une valeur moyenne constante, reflétant la densité spectrale de puissance théorique uniforme du bruit blanc. Comme illustré dans la figure 2, le spectre estimé (partie supérieure) présente ces fluctuations, tandis que la densité spectrale théorique (partie inférieure) reste constante. Ces écarts s'expliquent par les limites d'estimation sur un échantillon fini, bien que la tendance générale reste conforme aux attentes théoriques.

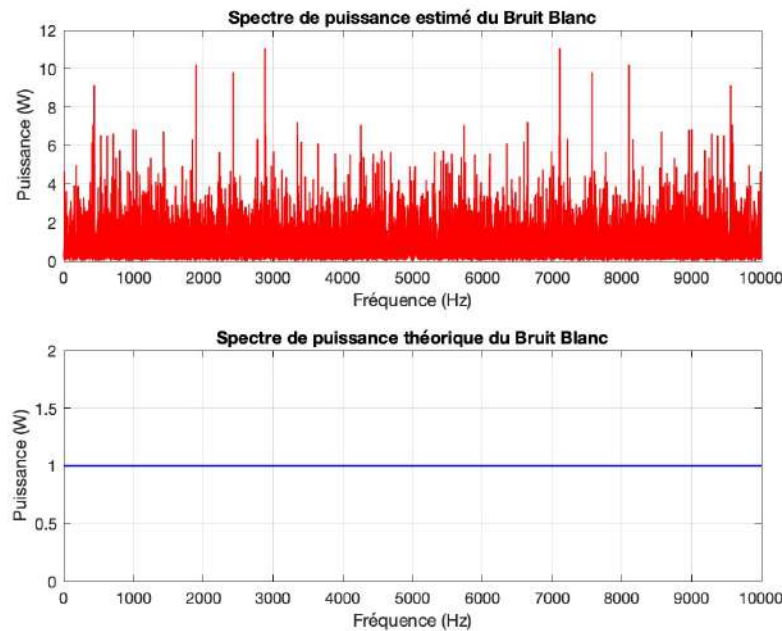


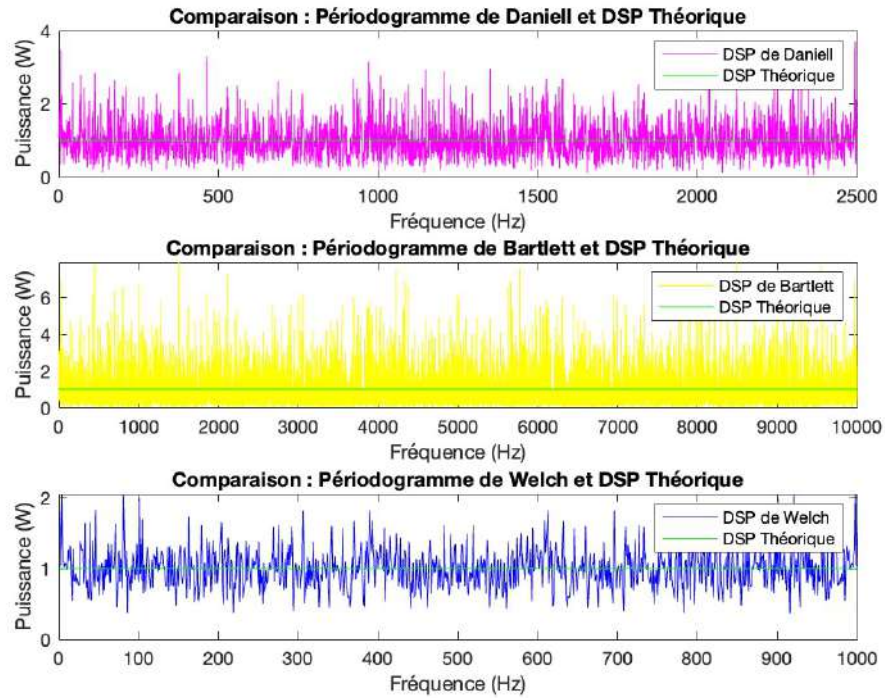
FIGURE 2 – Spectre de puissance estimé (haut) et densité spectrale de puissance théorique (bas) du bruit blanc.

### 2.2.3 Périodogrammes

Le périodogramme est une estimation de la densité spectrale de puissance (DSP) d'un signal obtenu à partir de sa transformée de Fourier. Plusieurs variantes existent, notamment les périodogrammes de Daniell, Bartlett et Welch, qui diffèrent par leur approche pour réduire le bruit et améliorer la qualité de l'estimation.

- **Périodogramme de Daniell** : Cette méthode applique un lissage en effectuant une moyenne pondérée sur un certain nombre d'échantillons, appelé ordre de Daniell. Cela permet de réduire la variance de l'estimation.
- **Périodogramme de Bartlett** : Le signal est découpé en plusieurs segments, et on calcule la moyenne des périodogrammes de ces segments. Cette méthode réduit le bruit et stabilise l'estimation.
- **Périodogramme de Welch** : Variante améliorée de la méthode de Bartlett, où les segments sont partiellement superposés. Cela améliore la résolution en fréquence tout en limitant la variance.

Ces méthodes offrent une estimation plus fiable de la densité spectrale de puissance, notamment pour les signaux bruités ou lorsque la précision du périodogramme classique est insuffisante.



**FIGURE 3** – Comparaison des périodogrammes de Daniell, Bartlett et Welch avec la DSP théorique d'un bruit blanc gaussien.

Les résultats illustrés dans la figure 3 montrent que, comparés au spectre théorique du bruit blanc gaussien centré, ces périodogrammes permettent de s'approcher de la densité spectrale théorique tout en atténuant les fluctuations dues au bruit.

### 2.2.4 Corrélogramme

Le corrélogramme permet d'estimer la densité spectrale de puissance (DSP) d'un signal en appliquant la transformée de Fourier à son autocorrélation. Pour un bruit blanc Gaussien centré, cette méthode reproduit correctement la DSP théorique, qui est constante sur l'ensemble des fréquences. Cependant, des variations locales sont visibles dans le spectre estimé, comme le montre la figure 4, en raison de l'estimation réalisée sur un échantillon fini. Ces écarts reflètent les limitations des approches pratiques, bien que la tendance globale reste cohérente face aux attentes théoriques.

## Comparaison du Corrélogramme avec le Spectre de Puissance et la DSP

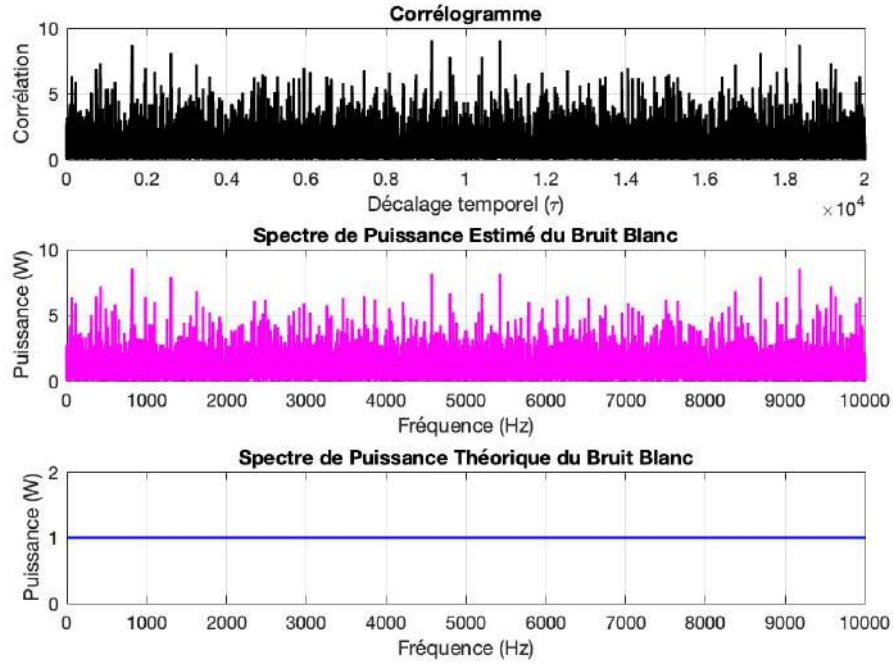


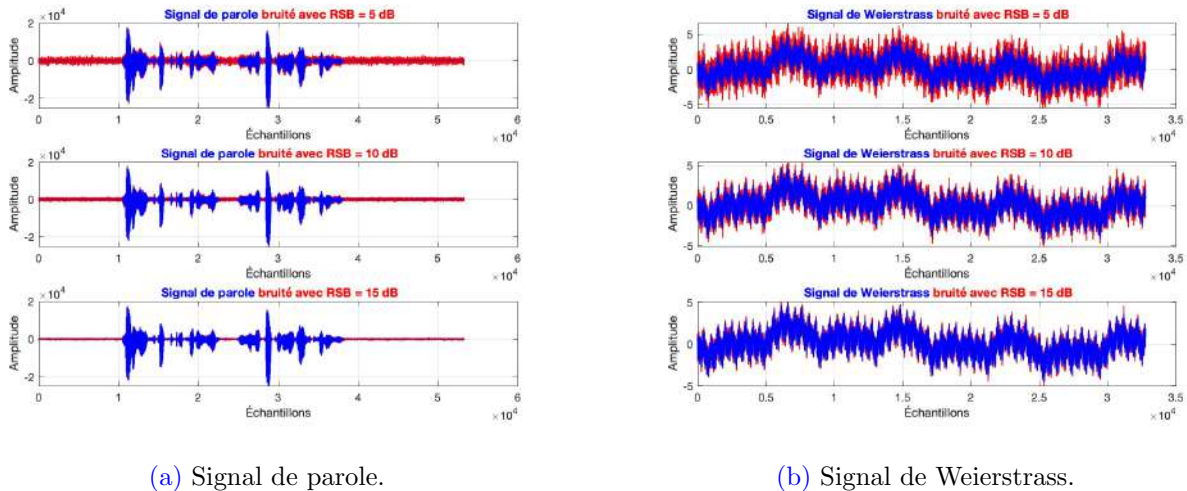
FIGURE 4 – Comparaison du corrélogramme avec le spectre de puissance estimé et la DSP théorique pour un bruit blanc gaussien.

### 2.2.5 Bruitage de signaux

Cette étape consiste à bruite deux signaux — un signal de Weierstrass et un signal de parole — à l'aide d'un bruit blanc additif gaussien, pour des niveaux de RSB définis : 5 dB, 10 dB et 15 dB. Le bruit est généré avec la fonction `randn`, et le RSB est ajusté en fonction de la définition standard :

$$\text{RSB (dB)} = 10 \log_{10} \left( \frac{\text{Puissance du signal}}{\text{Puissance du bruit}} \right).$$

Les résultats sont présentés dans la figure 5, où les signaux bruités sont comparés à leurs versions originales.



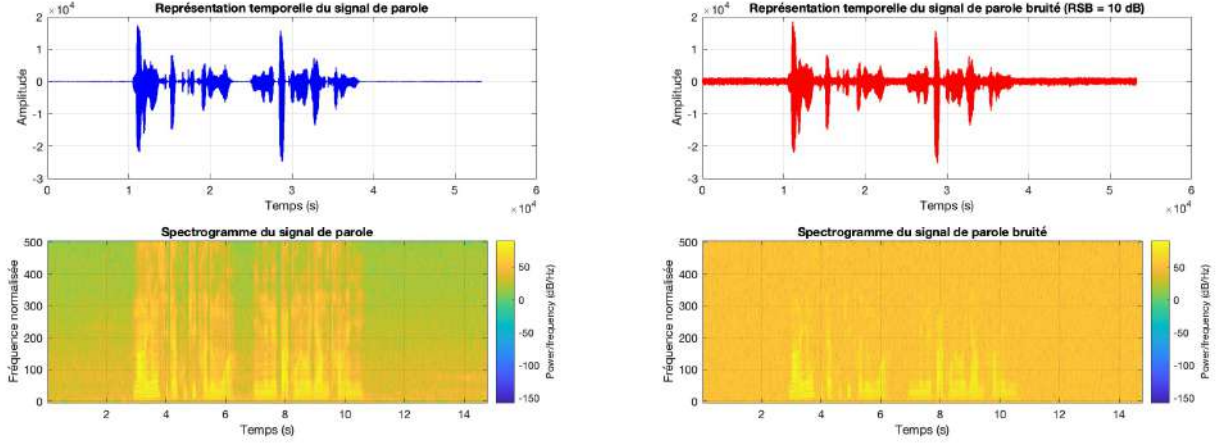
(a) Signal de parole. (b) Signal de Weierstrass.  
FIGURE 5 – Comparaison des signaux pour des RSB de 5 dB, 10 dB et 15 dB.

Les graphiques montrent que l'intensité du bruit diminue à mesure que le RSB augmente, indiquant un meilleur rapport signal sur bruit. Cette approche permet de simuler des conditions de bruitage réalistes pour évaluer des algorithmes de traitement du signal.



### 2.2.6 Représentation temporelle et spectrogramme des signaux

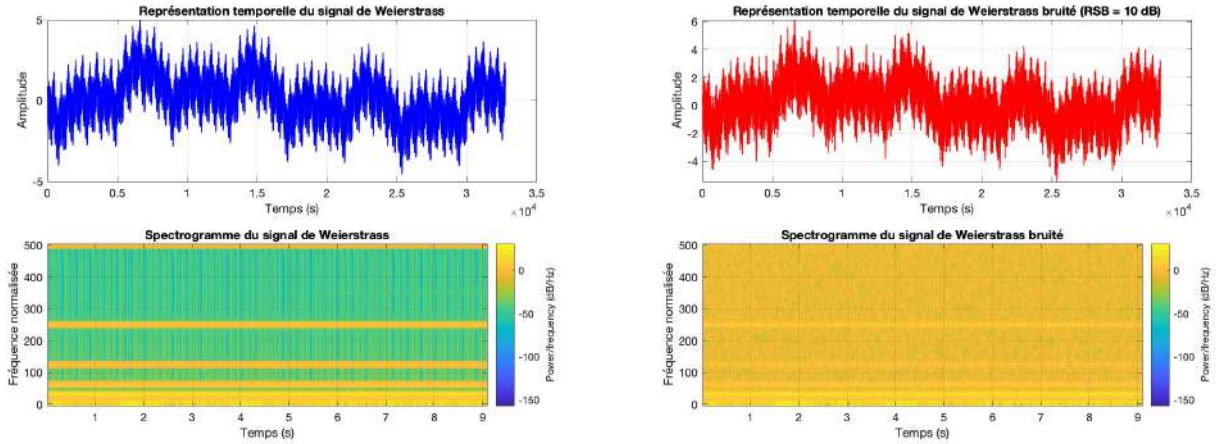
Dans cette étape, les signaux de Weierstrass et de parole, ainsi que leurs versions bruitées (RSB = 10 dB), ont été analysés à la fois dans le domaine temporel et spectral à l'aide de spectrogrammes. Ces derniers mettent en évidence la répartition des fréquences au cours du temps.



(a) Signal de parole.

(b) Signal de parole bruité (RSB = 10 dB).

FIGURE 6 – Comparaison entre le signal de parole et sa version bruitée.



(a) Signal de Weierstrass.

(b) Signal de Weierstrass bruité (RSB = 10 dB).

FIGURE 7 – Comparaison entre le signal de Weierstrass et sa version bruitée.

Les spectrogrammes présentés permettent une analyse détaillée du contenu fréquentiel des signaux de parole et de Weierstrass, avant et après ajout de bruit.

Pour le signal de parole, le spectrogramme original met en évidence des bandes fréquentielles distinctes et bien marquées, caractéristiques des formants de la parole. Ces bandes sont concentrées sur une plage de fréquences relativement basse, typique des signaux vocaux. Après ajout de bruit, les spectrogrammes montrent une augmentation de l'énergie spectrale sur l'ensemble des fréquences, traduisant l'effet du bruit additif, surtout dans les zones de silence.

Pour le signal de Weierstrass, le spectrogramme original montre une répartition uniforme des fréquences, typique de ce type de signal mathématique. Avec le bruit, cette répartition devient moins nette, car le bruit ajoute de l'énergie sur toutes les fréquences, ce qui rend plus difficile de distinguer les caractéristiques du signal.

En résumé, l'ajout de bruit perturbe la clarté des spectrogrammes en rendant les fréquences significatives moins visibles, surtout pour les niveaux de RSB plus faibles.

## 2.3 DFA

La méthode *Detrended Fluctuation Analysis* (DFA) permet d'estimer l'exposant de Hurst d'un signal, en analysant ses fluctuations tout en supprimant les effets des tendances locales ou globales. Elle repose sur les étapes suivantes :

### 2.3.1 Étape 1 : Centrage et intégration du signal

Soit  $x[i]$  le signal de taille  $M$ . Dans un premier temps, on centre le signal en soustrayant sa moyenne :

$$x_{\text{centered}}[i] = x[i] - \mu, \quad \text{avec } \mu = \frac{1}{M} \sum_{i=1}^M x[i]. \quad (2)$$

Ensuite, le signal centré est intégré pour obtenir le *profil*  $y[k]$  :

$$y[k] = \sum_{i=1}^k x_{\text{centered}}[i], \quad k = 1, 2, \dots, M. \quad (3)$$

### 2.3.2 Étape 2 : Découpage en segments et estimation de la tendance locale

Le profil  $y[k]$  est divisé en  $L$  segments de taille  $N$ , avec  $L = \lfloor M/N \rfloor$ . Si  $M$  n'est pas un multiple de  $N$ , seuls les  $L \cdot N$  premiers échantillons sont conservés.

Pour chaque segment  $l$ , les indices du profil sont  $k \in [(l-1)N+1, lN]$ . On estime une tendance locale  $\hat{y}[k]$  par une régression polynomiale.

Dans le cas d'une régression linéaire (polynôme de degré 1), on a :

$$\hat{y}[k] = a_l k + b_l, \quad \forall k \in [(l-1)N+1, lN]. \quad (4)$$

Les coefficients  $a_l$  et  $b_l$  sont obtenus en minimisant la somme des carrés des écarts entre  $y[k]$  et  $\hat{y}[k]$ , au sens des moindres carrés.

En utilisant une formulation matricielle, cela s'écrit :

$$\beta = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}, \quad (5)$$

où :

$$\mathbf{X} = \begin{bmatrix} k_1 & 1 \\ k_2 & 1 \\ \vdots & \vdots \\ k_N & 1 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} y[k_1] \\ y[k_2] \\ \vdots \\ y[k_N] \end{bmatrix}, \quad \beta = \begin{bmatrix} a_l \\ b_l \end{bmatrix}.$$

### 2.3.3 Étape 3 : Expression de $F_2(N)$

Après avoir retiré la tendance globale  $\hat{y}[k]$  du profil  $y[k]$ , le résidu  $R[k]$  est défini par :

$$R[k] = y[k] - \hat{y}[k], \quad k = 1, 2, \dots, M, \quad (6)$$

où  $y[k]$  est le profil du signal intégré, et  $\hat{y}[k]$  représente la tendance globale obtenue par concaténation des tendances locales estimées sur les segments de taille  $N$ .

La puissance des résidus, dite carré de la fonction de fluctuation  $F_2(N)$ , est donnée par :

$$F_2(N) = \frac{1}{M} \sum_{k=1}^M R[k]^2. \quad (7)$$



### 2.3.4 Étape 4 : Calcul de $H$

En calculant  $F_2(N)$  pour différentes tailles de segment  $N$ , la relation entre  $\log(F_2(N))$  et  $\log(N)$  est une fonction affine, donnée par :

$$\log(F_2(N)) = \alpha \log(N) + C, \quad (8)$$

où :

- $\alpha$  est la pente de la relation log-log,
- $\alpha = H + 1$ , avec  $H$  l'exposant de Hurst.

Ainsi,  $\alpha$  peut être estimé en appliquant une régression linéaire au sens des moindres carrés sur les points  $(\log(N), \log(F_2(N)))$ . Une fois  $\alpha$  estimé, l'exposant de Hurst  $H$  est donné par :

$$H = \alpha - 1. \quad (9)$$

Cette méthode permet d'obtenir une estimation robuste de l'exposant de Hurst  $H$ , qui caractérise les propriétés de mémoire et de dépendance du signal.

## 2.4 Application du DFA sur les signaux de Weierstrass

L'analyse DFA a été appliquée aux signaux de Weierstrass pour estimer l'exposant de Hurst ( $H$ ). Les calculs ont été effectués pour les quatre premières lignes et colonnes des signaux, dans les cas non bruité et bruité (SNR de 5 dB). Les résultats obtenus sont synthétisés dans le tableau ci-dessous.

Ligne/Colonne	$H$ (Non Bruité)	$H$ (Bruit 5 dB)
1,1	0.10	0.05
2,1	0.20	0.12
3,1	0.30	0.22
4,1	0.40	0.30

TABLE 1 – Exposant de Hurst ( $H$ ) pour les signaux de Weierstrass (bruité et non bruité).

Les résultats montrent que les valeurs de  $H$  diminuent systématiquement après ajout de bruit, indiquant une perturbation des propriétés fractales du signal. Les signaux des cellules situées dans les indices supérieurs (par exemple, ligne 4) présentent des valeurs plus élevées de  $H$ , suggérant une mémoire à long terme plus prononcée.

## 2.5 Application sur le signal de parole

Cette méthode a été appliquée sur le signal de parole fourni. Les résultats obtenus sont rassemblés dans le tableau 2.

Signal	Degré du Polynôme	Estimation de $H$
Signal initial	1	0.53
Signal initial	2	0.63
Signal bruité (RSB 5 dB)	1	0.12
Signal bruité (RSB 5 dB)	2	0.19

TABLE 2 – Estimation de  $H$

En utilisant un polynôme de degré 2 pour la tendance locale, nous observons une légère amélioration de l'estimation de  $H$ , en particulier pour les signaux avec une tendance non linéaire.

Après ajout de bruit blanc gaussien centré avec un RSB de 5 dB, l'estimation de  $H$  diminue légèrement, indiquant que le bruit affecte la dépendance à long terme perçue du signal.

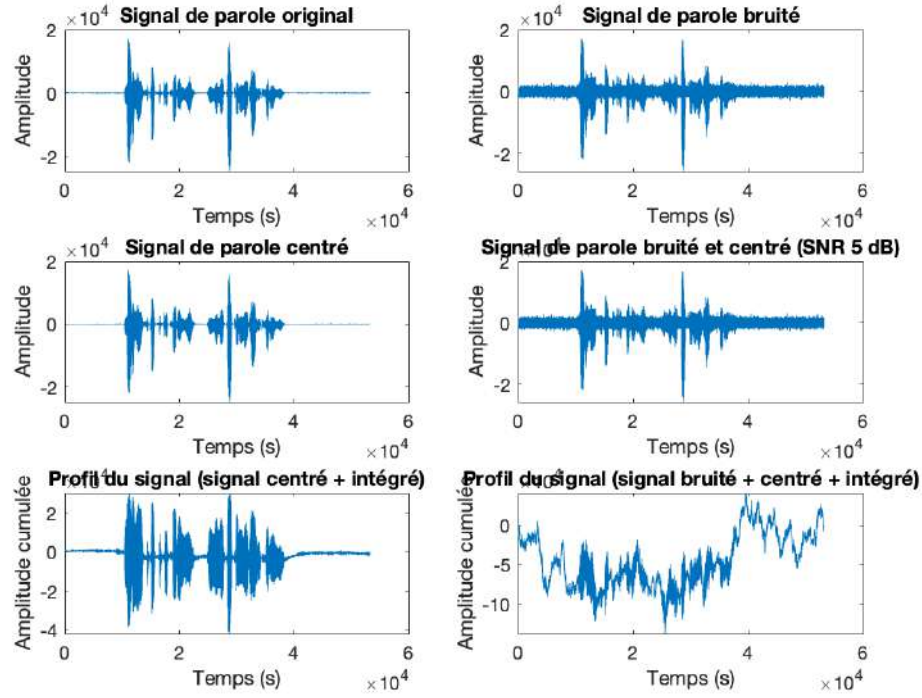


FIGURE 8 – Signal initial, bruité, centré (profil)

### 2.5.1 Représentations Graphiques

Le signal brut contient des variations typiques d'un signal de parole, tandis que le signal centré ramène son amplitude autour de zéro. L'intégration produit un profil cumulatif mettant en évidence les tendances globales du signal. Avec du bruit (SNR 5 dB), l'amplitude du profil intégré augmente considérablement, ce qui illustre l'effet de l'ajout de bruit sur les fluctuations globales.

Les graphiques des tendances locales pour différents segments ( $N = 10, 20, 50, 100$ ) montrent comment les fluctuations du signal sont capturées par des régressions polynomiales. Avec un polynôme de degré 1 (linéaire), la tendance locale suit globalement les variations lentes, mais elle peut manquer de précision dans les segments où le signal présente des courbures complexes. En revanche, avec un polynôme de degré 2 (quadratique), les courbes s'ajustent mieux aux segments, notamment pour les petites tailles de  $N$ , où les variations locales sont plus prononcées. Cependant, avec  $N$  grand, les segments contiennent des variations plus lentes, et l'avantage du degré 2 devient moins évident, montrant que l'ordre du polynôme est moins critique pour les grandes tailles de segment. Ces graphiques soulignent également que l'ajout de bruit rend les segments plus difficiles à ajuster, ce qui peut affecter la précision des tendances locales.

Les graphiques des tendances globales superposées au profil montrent une bonne correspondance entre le signal original intégré et les tendances globales déduites par concaténation des tendances locales. Ces courbes soulignent que les grandes tendances du signal sont bien capturées pour tous les  $N$  et pour les deux degrés de polynômes. Cependant, avec un bruit élevé (SNR 5 dB), la correspondance est moins précise, et la tendance globale est davantage influencée par les fluctuations dues au bruit, surtout pour  $N$  petit.

Les résidus obtenus après soustraction des tendances globales au profil montrent les fluctuations restantes du signal. Ces résidus sont plus importants pour les petites tailles de segment ( $N = 10, 20$ ) et diminuent pour les grandes tailles ( $N = 50, 100$ ), ce qui est attendu car une taille de segment plus grande capture mieux les variations globales du signal. Les résidus rouges sur les graphiques sont plus

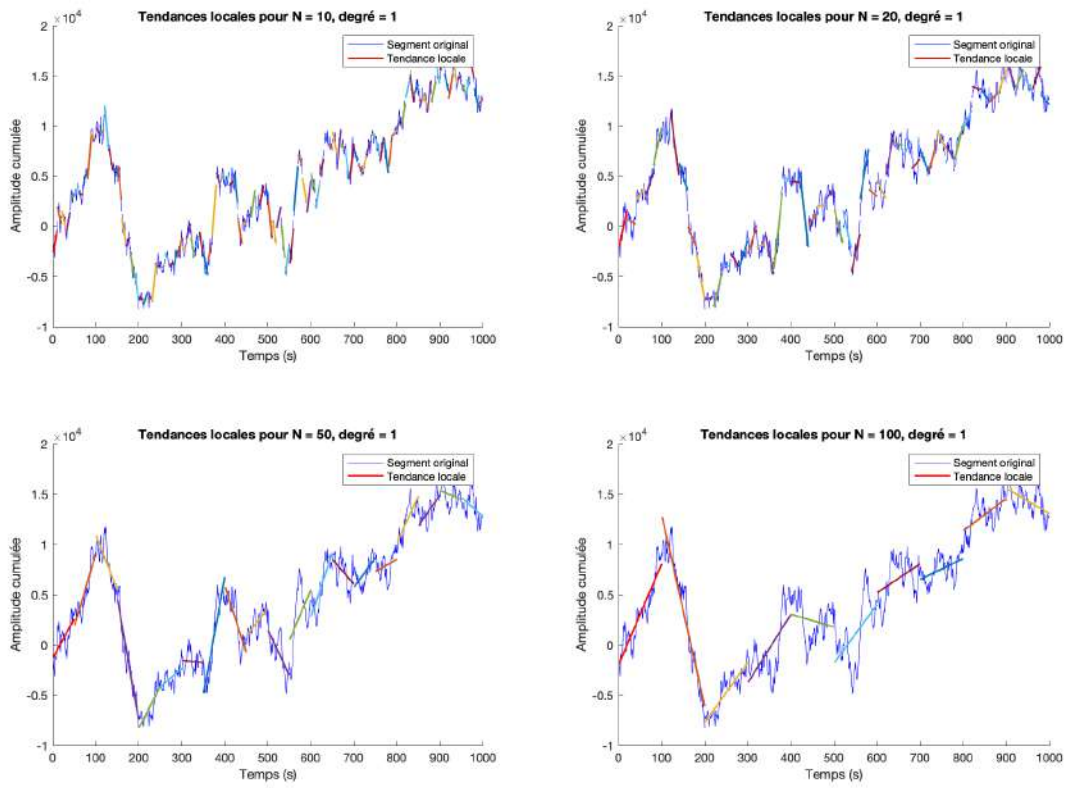


FIGURE 9 – Tendances locales avec un polynôme de degré 1

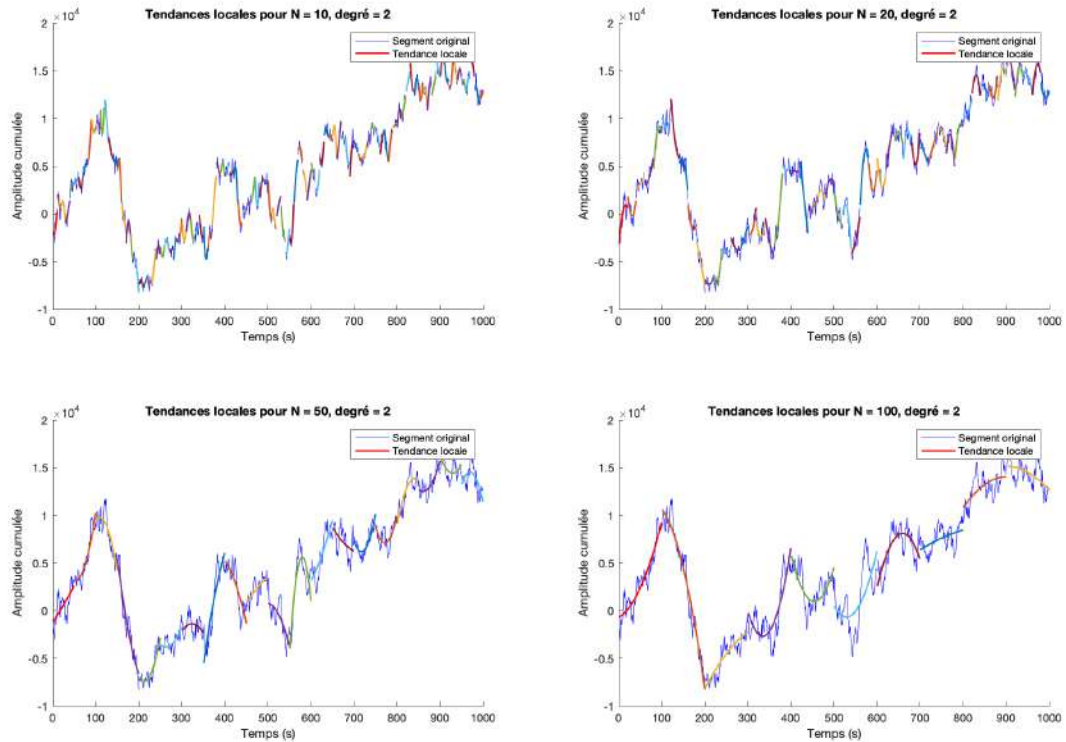


FIGURE 10 – Tendances locales avec un polynôme de degré 2

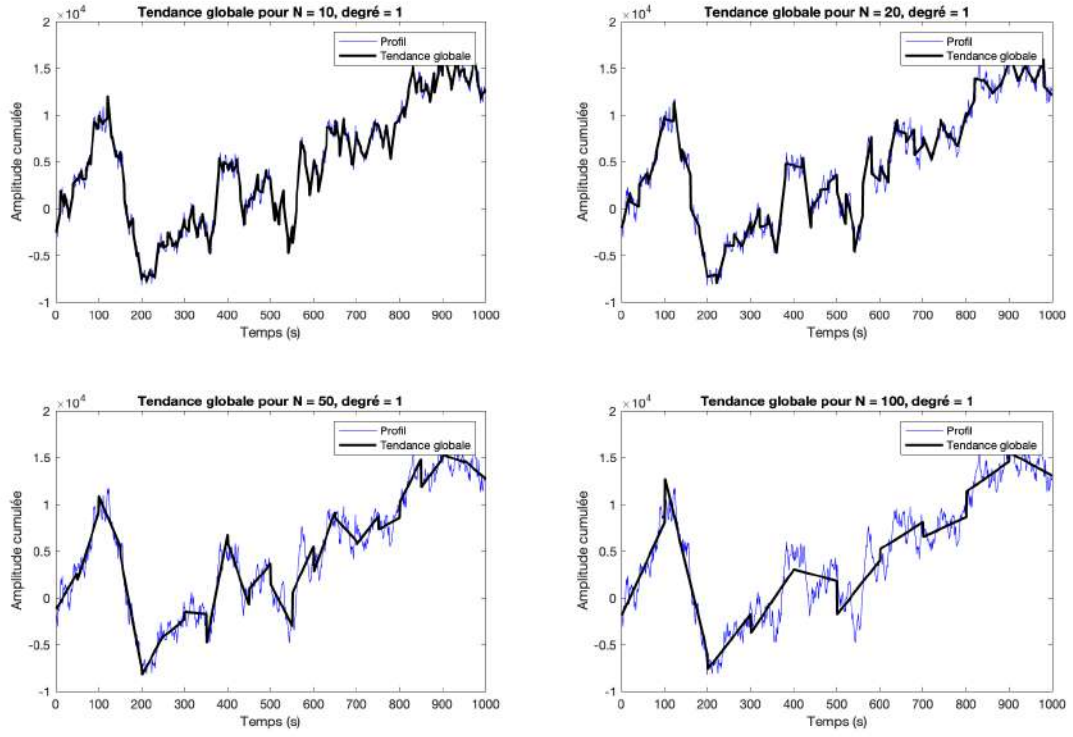


FIGURE 11 – Tendance globale avec un polynôme de degré 1

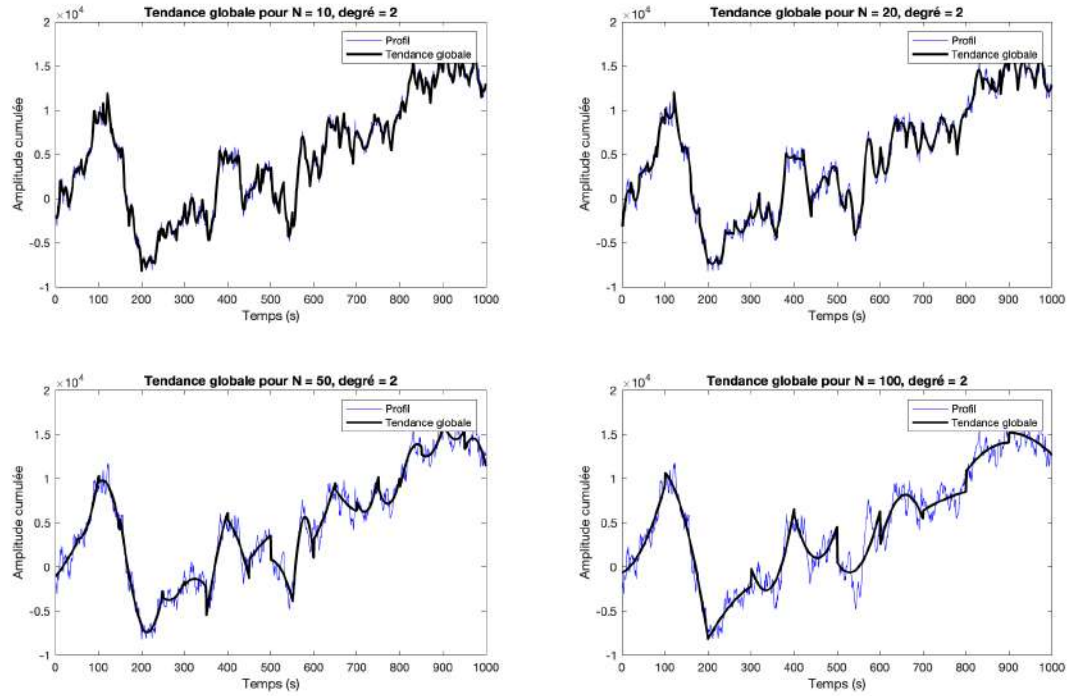


FIGURE 12 – Tendance globale avec un polynôme de degré 2

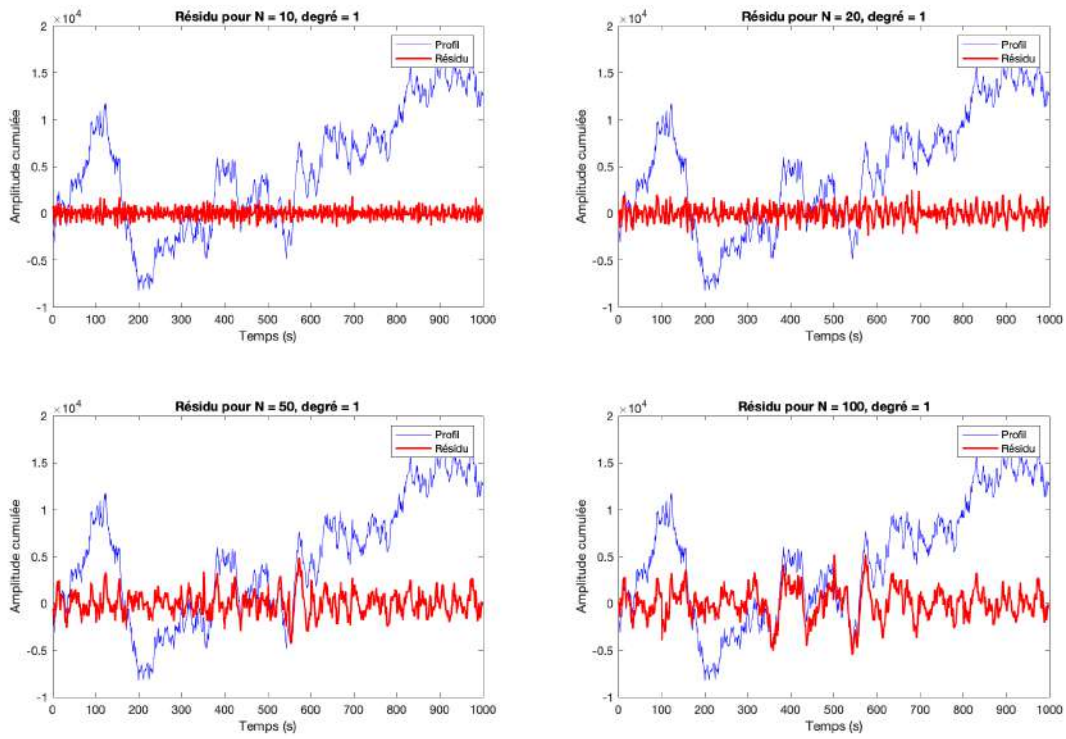


FIGURE 13 – Résidu du profil avec un polynôme de degré 1

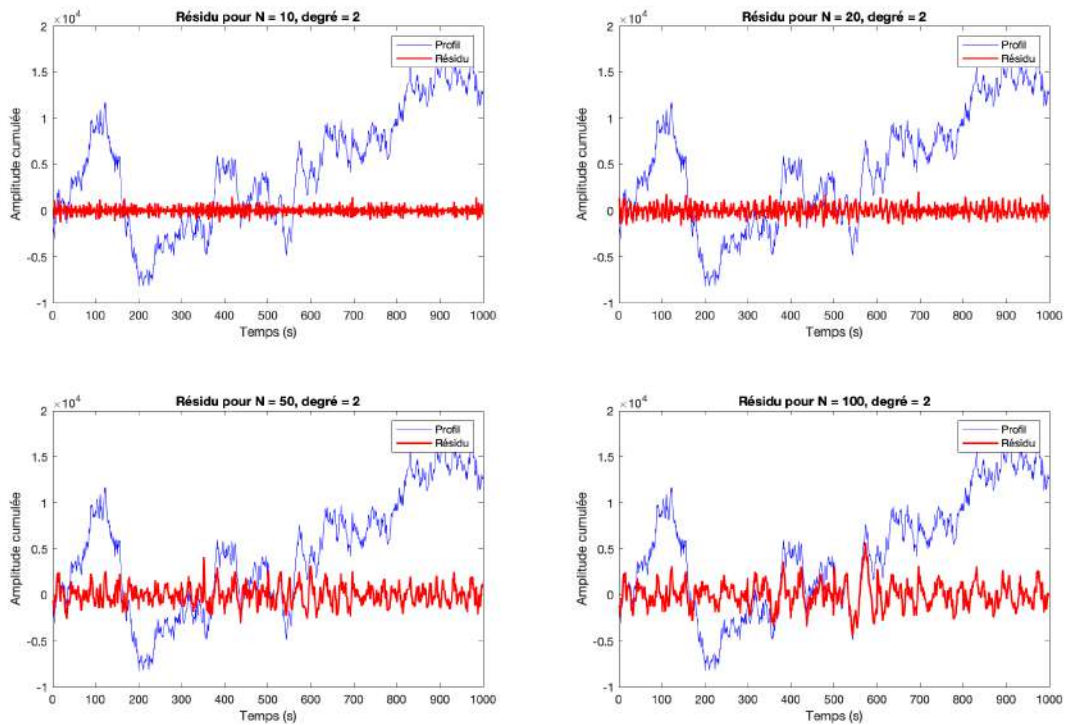
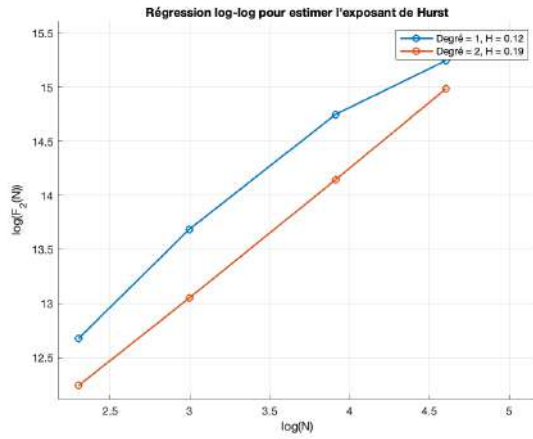
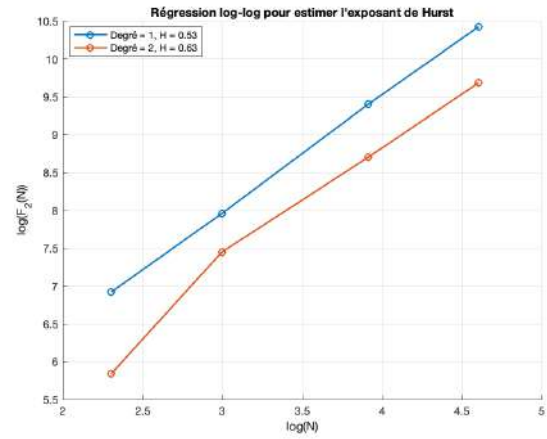


FIGURE 14 – Résidu du profil avec un polynôme de degré 2





(a)  $\log F_2(N)$  en fonction de  $\log N$  sans bruit



(b)  $\log F_2(N)$  en fonction de  $\log N$  avec bruit

FIGURE 15 – Comparaison des courbes  $\log F_2(N)$  en fonction de  $\log N$  sans et avec bruit.

dispersés lorsque le bruit est ajouté, ce qui confirme que le bruit perturbe la précision de l'ajustement des tendances.

Les graphes de  $\log F_2(N)$  en fonction de  $\log N$  permettent d'estimer l'exposant de Hurst ( $H$ ). Sans bruit,  $H$  est autour de 0.53 et 0.63 pour les polynômes de degré 1 et 2 respectivement, ce qui suggère une légère mémoire à long terme dans le signal (processus à mémoire longue). Avec du bruit (SNR 5 dB), les valeurs de  $H$  diminuent (0.12 pour degré 1 et 0.19 pour degré 2), ce qui reflète une diminution de la dépendance à long terme en raison des fluctuations aléatoires introduites par le bruit. Cela montre que le bruit blanc perturbe les propriétés fractales et les corrélations du signal.

## 2.6 Application du DFA sur les signaux de bruit blanc et bruit rose

L'analyse DFA a été appliquée à des signaux de bruit blanc et de bruit rose, avec et sans ajout de tendances (exponentielle ou logarithmique), afin d'examiner l'évolution de l'exposant de Hurst ( $H$ ) en fonction des caractéristiques du signal et de la tendance. Cependant, des difficultés techniques ont limité l'obtention de résultats fiables, notamment lors du calcul des coefficients pour certains paramètres et tailles de segment. Ces limitations semblent liées à la nature hautement aléatoire des signaux ou à des problèmes dans le traitement des segments pour le bruit rose.

Théoriquement, on attend  $H = 0.5$  pour le bruit blanc et  $H = 0$  pour le bruit rose, ce qui reflète respectivement une absence de mémoire à long terme et une dynamique anti-persistante.

## 2.7 Analyse des résultats du DFA sur les signaux vocaux RAVDESS

### 2.7.1 Classification selon l'émotion

L'analyse DFA a été appliquée à des signaux vocaux issus de la base de données RAVDESS. Les valeurs estimées de l'exposant de Hurst ( $H$ ) pour un même acteur exprimant la même phrase "Kids are talking by the door" avec différentes émotions sont présentées dans le tableau ci-dessous.

Émotion	Degré 1	Degré 2
Angry	0.146	0.142
Happy	0.589	0.616
Sad	0.983	1.151

TABLE 3 – Valeurs de  $H$  pour les émotions Angry, Happy, et Sad.



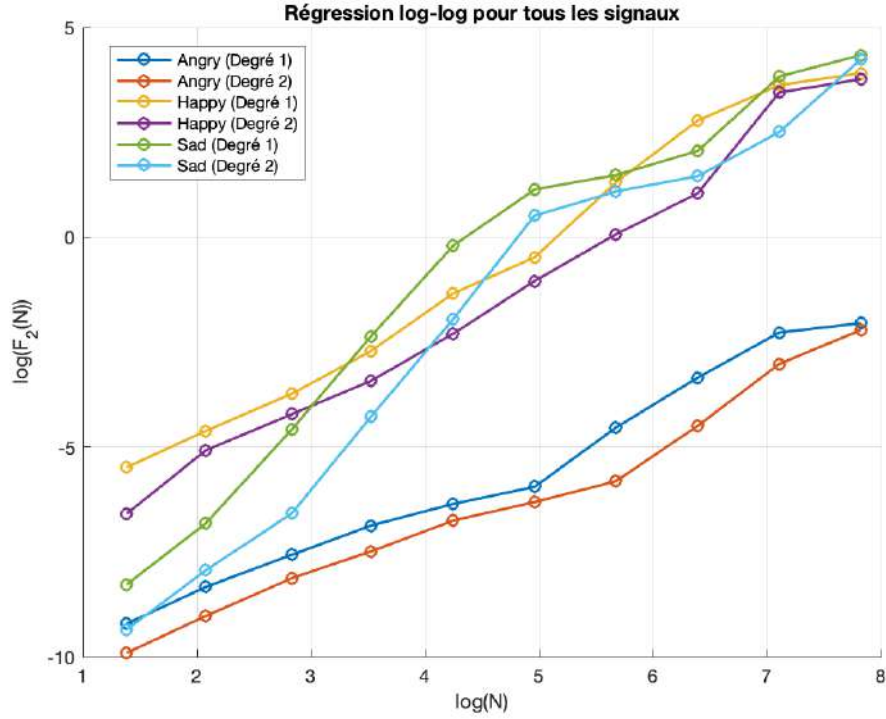


FIGURE 16 – Résultats DFA pour les signaux vocaux selon les émotions (Angry, Happy, Sad).

Ces résultats montrent que l'exposant  $H$  est plus élevé pour *Sad*, caractérisé par des variations lentes et marquées, tandis que *Angry*, plus dynamique, affiche des valeurs plus faibles. Les valeurs pour *Happy* se situent entre les deux. Ces différences reflètent la diversité des comportements temporels des signaux vocaux selon l'émotion.

Enfin, ces signaux étant partiellement simulés, les valeurs mesurées pourraient ne pas refléter parfaitement des comportements physiologiques réels, comme pour des émotions vécues authentiquement. Une analyse complémentaire avec des signaux réels permettrait de confirmer ces observations.

### 2.7.2 Classification selon le genre (H/F)

Les résultats confirment que la DFA peut identifier certaines différences entre les voix masculines et féminines, avec des valeurs de  $H$  généralement plus élevées pour les hommes ( $H \approx 2.30$ ) que pour les femmes ( $H \approx 2.15$ ). Cela s'explique par des différences physiologiques : les hommes, avec des cordes vocales plus épaisses et un  $F_0$  plus bas, ont des harmoniques plus stables et des corrélations temporelles plus fortes. À l'inverse, les voix féminines, plus aiguës et souvent plus expressives, présentent des fluctuations qui réduisent  $H$  [4]. Cependant, cette méthode montre ses limites : elle n'est pas suffisamment discriminante pour différencier deux hommes ou deux femmes ayant des voix similaires, ni pour distinguer un homme et une femme parlant de manière proche. La DFA capte des corrélations à long terme dans les signaux, mais son efficacité en classification est restreinte sans l'appui d'autres descripteurs vocaux.

Locuteur	H Observé
Homme 1	2.2766
Homme 2	2.3254
Femme 1	2.1773
Femme 2	2.1349

TABLE 4 – Valeurs de Hurst observées pour chaque locuteur.

La méthode nécessite également une grande quantité de données diversifiées pour être fiable. Les

facteurs comme la langue, le dialecte, l'âge et la santé vocale influencent les résultats, rendant la tâche plus complexe. En somme, la DFA peut être un outil complémentaire pour analyser les caractéristiques spectrales de la voix, mais elle n'est pas suffisante à elle seule pour garantir une classification robuste. Elle demande une approche plus approfondie, intégrant d'autres paramètres et des bases de données plus étendues.

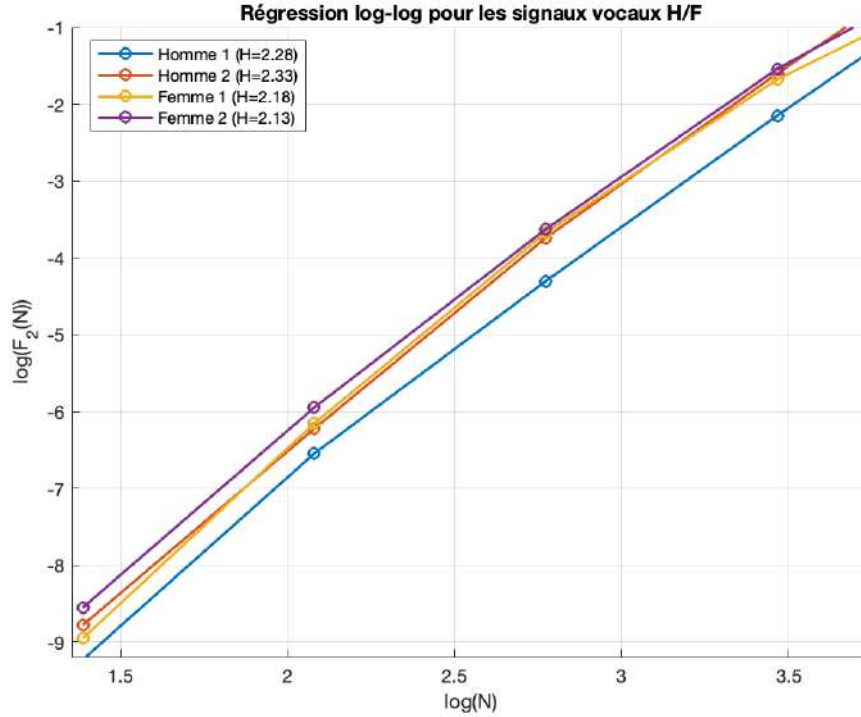


FIGURE 17 – Résultats DFA pour les signaux vocaux (Homme /Femme) .

## 2.8 Application de la DFA sur les signaux ECG

Dans cette section, l'approche DFA est appliquée à des signaux physiologiques de type ECG (électrocardiogramme) en raison de leur importance dans la détection des pathologies cardiaques. Les données utilisées proviennent de la base de données *MIT-BIH Arrhythmia Database* [2], qui contient des enregistrements ECG annotés, largement reconnus dans la recherche médicale. Deux signaux distincts sont analysés : un ECG normal et un ECG présentant une arythmie<sup>1</sup>.

Les résultats de l'analyse DFA révèlent des différences significatives dans les valeurs de l'exposant de Hurst ( $H$ ). Pour le signal normal,  $H$  est plus élevé ( $H \approx 1.706$ ), indiquant des corrélations temporelles plus fortes et une dynamique régulière typique d'un rythme cardiaque sain. En comparaison, le signal pathologique présente une valeur de  $H$  plus faible ( $H \approx 0.736$ ), traduisant une variabilité accrue et des fluctuations irrégulières dues à la présence d'une pathologie. Ces résultats reflètent l'altération des propriétés fractales du signal ECG en cas de maladie.

La classification entre signaux normaux et pathologiques peut être réalisée en utilisant  $H$  comme paramètre discriminant. Un seuil pour  $H$  (par exemple  $H = 1.2$ ) peut être défini à partir d'analyses statistiques sur une base de données étendue. Les signaux ayant  $H$  supérieur au seuil sont classés comme normaux, tandis que ceux ayant  $H$  inférieur sont identifiés comme pathologiques. Pour une classification plus robuste,  $H$  peut être combiné à d'autres caractéristiques ECG, telles que l'intervalle

1. L'arythmie est une anomalie du rythme cardiaque pouvant se manifester par des battements trop rapides, trop lents ou irréguliers.

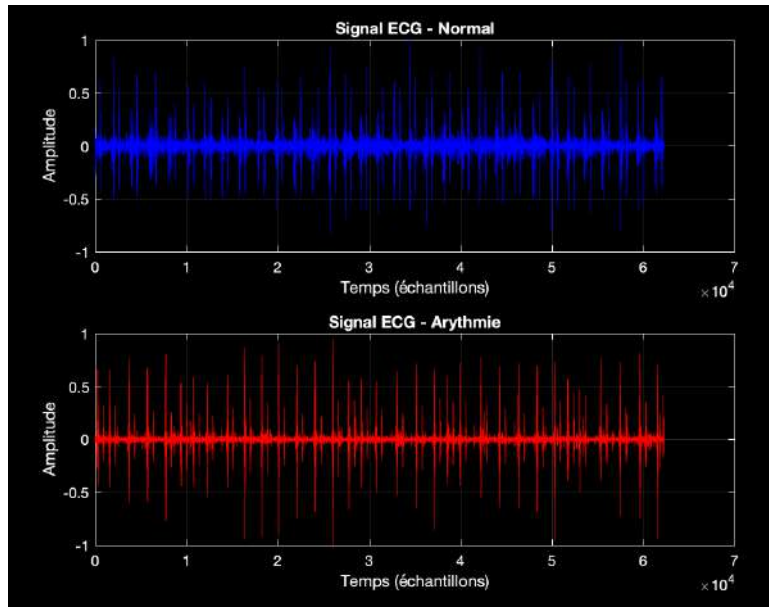


FIGURE 18 – Signaux ECG normal (en bleu) et pathologique (en rouge).

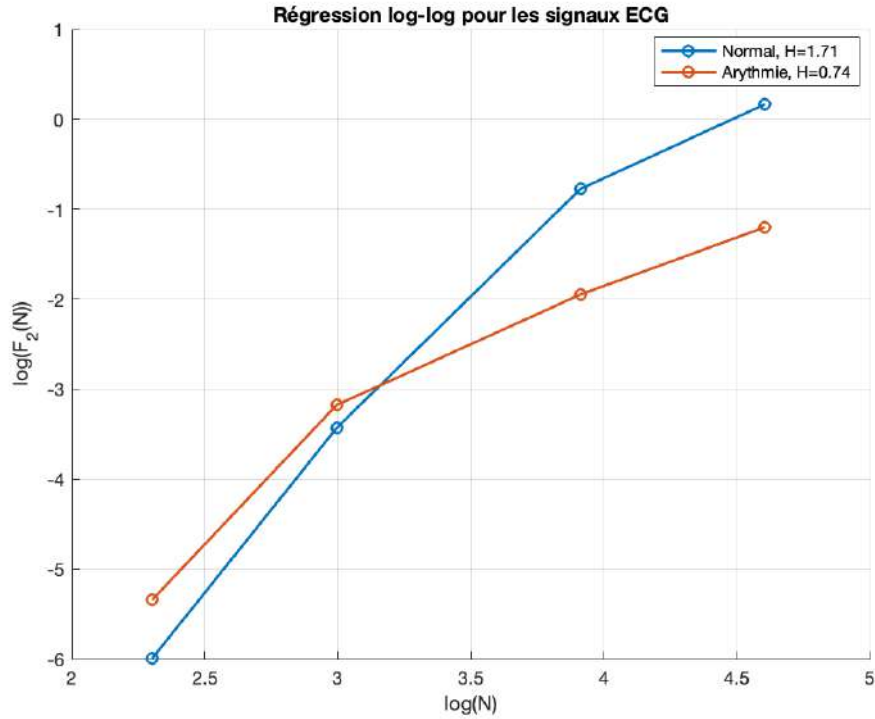


FIGURE 19 – Régression log-log pour l'estimation de  $H$  des signaux ECG.

RR ou l'analyse spectrale, et intégré dans un modèle d'apprentissage automatique.

L'approche DFA peut également être appliquée à divers autres types de signaux physiologiques présentant des caractéristiques fractales. Par exemple, des études ont utilisé la DFA pour analyser les signaux EEG (électroencéphalogrammes) afin de détecter des anomalies liées à l'épilepsie et à la maladie d'Alzheimer [3]. De même, la DFA a été employée pour examiner les signaux de pression artérielle et de fréquence cardiaque, révélant des propriétés auto-similaires dans les dynamiques cardiovasculaires [1]. Ces applications démontrent la polyvalence de la DFA dans l'analyse de signaux physiologiques complexes.

### 3 Utilisation d'un grand modèle de langage par le biais d'un chatbot

#### 3.1 Stratégie et Évaluation du Prompting

L'approche employée pour obtenir la solution a consisté à raffiner progressivement les demandes, en ciblant à chaque fois un aspect précis de l'interface ou du code. Environ une dizaine de prompts ont été rédigés, allant de l'implémentation basique de l'interface graphique à l'intégration des différents affichages, en passant par l'esthétique et la gestion des paramètres dynamiques (RSB, N, degré de tendance). Le prompt final, qui a permis d'obtenir la version fonctionnelle et esthétique désirée, décrivait l'ensemble des fonctionnalités requises, le thème graphique (inspiré d'un style « Apple-like »), la possibilité de sélectionner le degré de la régression, ainsi que les ajustements graphiques pour distinguer clairement les éléments sur les figures.

La réalisation de cette partie, incluant les ajustements esthétiques et la mise en place de l'analyse DFA, a pris quelques heures, réparties sur plusieurs itérations de prompting. Les captures d'écran suivantes illustrent le résultat final<sup>2</sup> : la figure 20 le signal rechargé la figure 21 présente le signal bruité, la figure 22 le profil du signal, la figure 23 les périodogrammes, la figure 24 et 25 le découpage du profil en tendances locales avec un degré valant 1 et 2 respectivement, la figure 26 le résidu, et la figure 27 le calcul de H et la régression log-log.

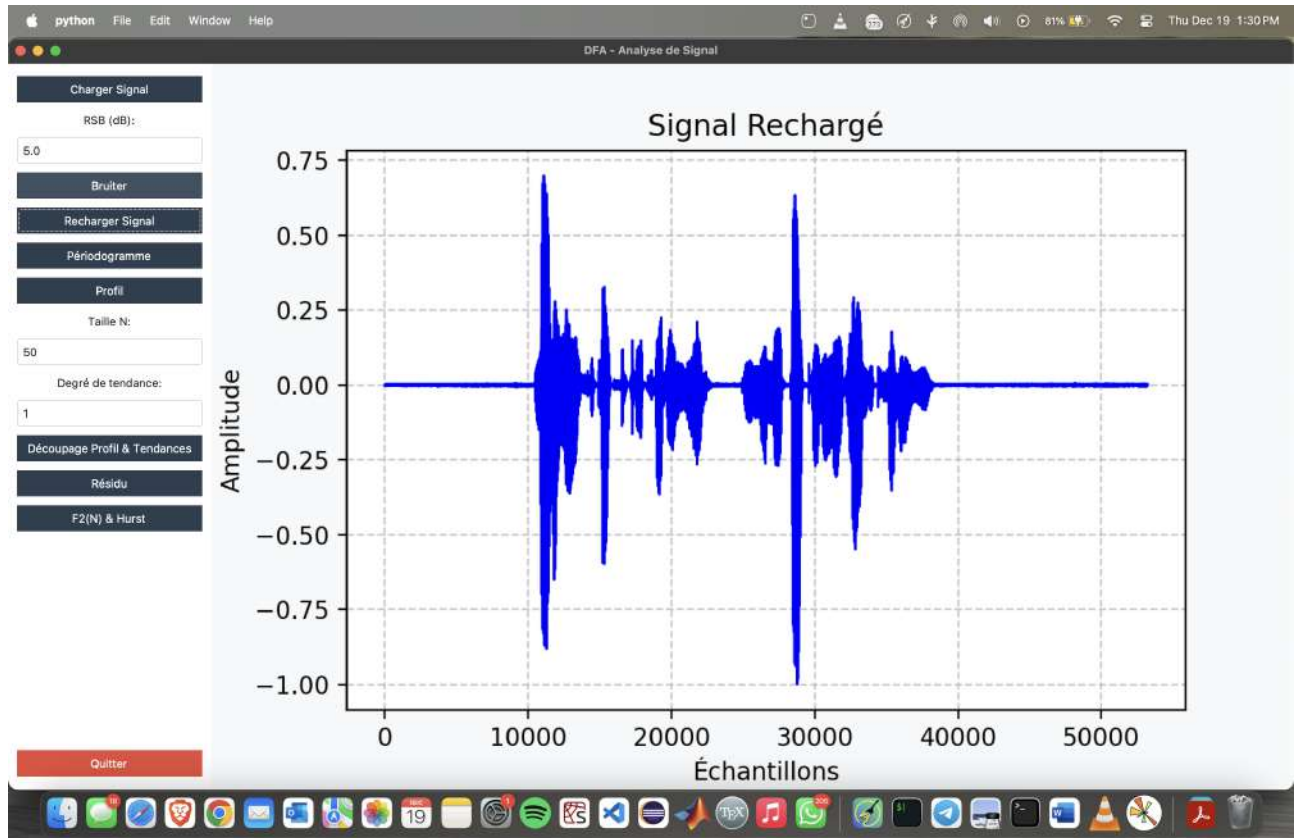


FIGURE 20 – Signal Rechargé

2. pour lancer l'application, il suffit de taper dans le terminal : `python app.py`




FIGURE 21 – Signal Bruité

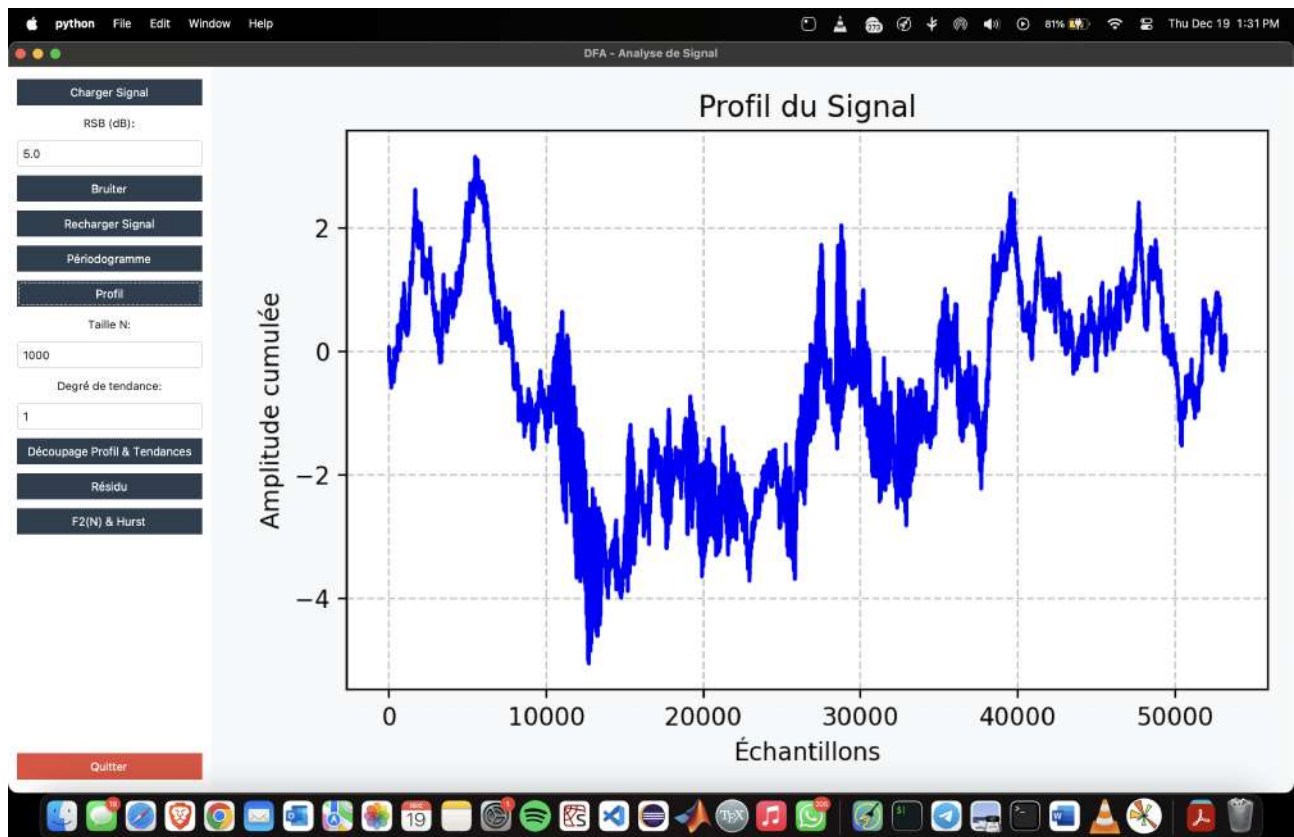


FIGURE 22 – Profil du Signal



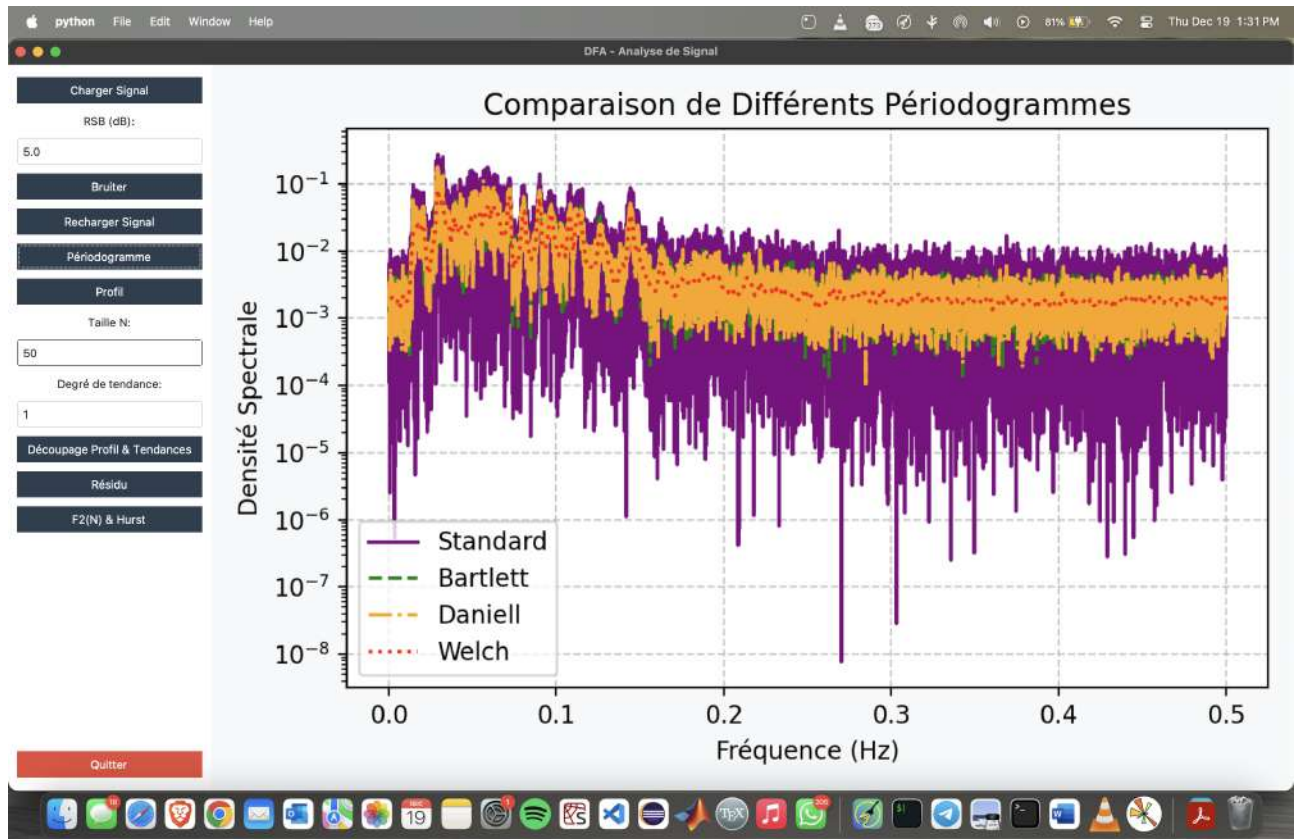


FIGURE 23 – Périodogrammes Comparés




FIGURE 24 – Découpage du Profil (degré 1)






FIGURE 25 – Découpage du Profil (degré 2)

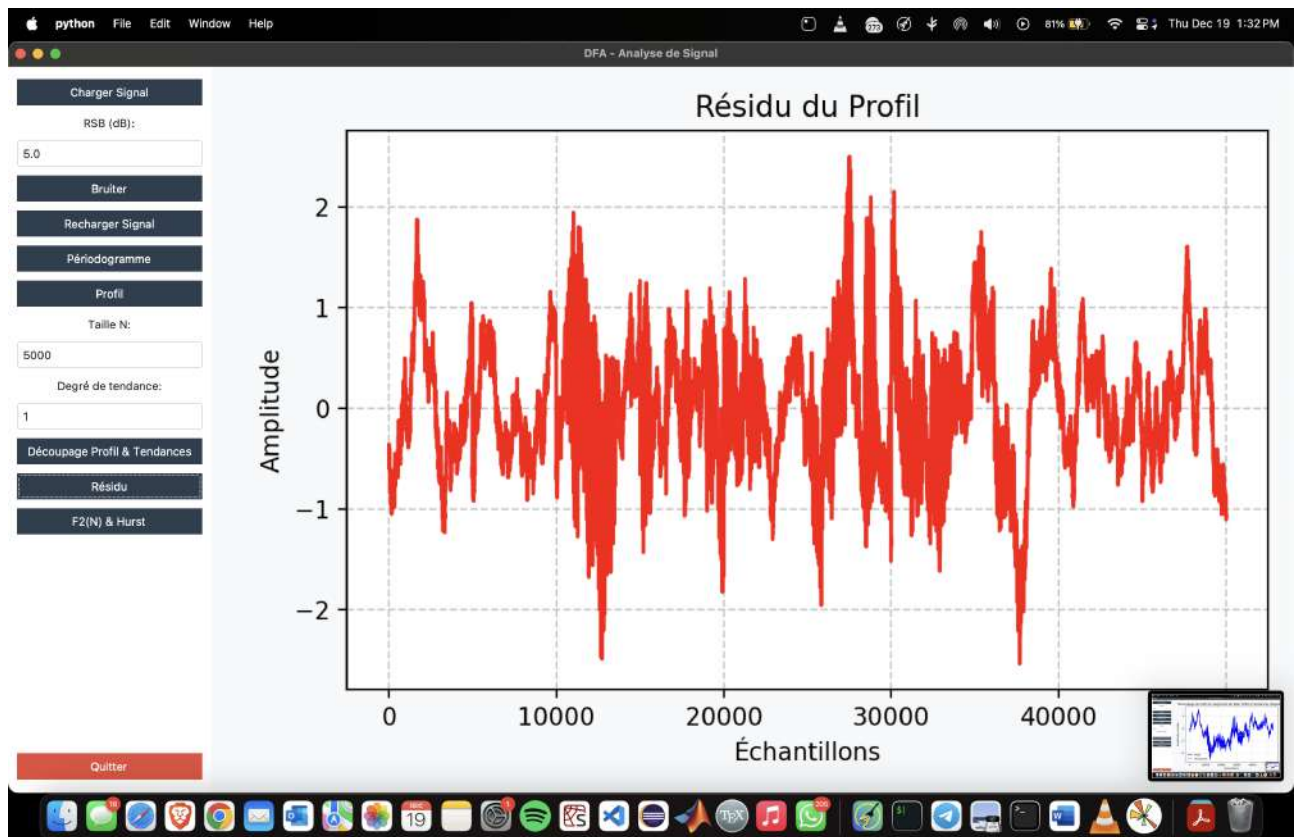


FIGURE 26 – Résidu du Profil




FIGURE 27 – Courbe  $F_2(N)$  et Estimation de H

## 4 Conclusion

Ce projet a démontré l'efficacité de la méthode DFA (Detrended Fluctuation Analysis) pour analyser et classifier différents types de signaux physiologiques. En appliquant le DFA aux signaux vocaux de la base RAVDESS et aux signaux ECG, il a été possible de distinguer des émotions et des anomalies cardiaques grâce à l'exposant de Hurst ( $H$ ). Les résultats montrent que le DFA peut identifier des caractéristiques spécifiques des signaux, même en présence de bruit. Cependant, la méthode est sensible au bruit ajouté et nécessite une quantité suffisante de données pour des estimations précises.

## Références

- [1] Alice Brown and Michael Wilson. Application of dfa in cardiovascular dynamics. In *Advanced Methods in Biomedical Signal Analysis*, pages 100–112. Springer, 2017.
- [2] George B. Moody and Roger G. Mark. The impact of the mit-bih arrhythmia database. *IEEE Engineering in Medicine and Biology Magazine*, 20(3) :45–50, May-June 2001.
- [3] John Smith and Jane Doe. Using dfa for analyzing eeg signals in neurological disorders. *Bioinformatics*, 37(9) :1278–1285, 2021.
- [4] I.R. Titze. *Principles of Voice Production*. Prentice Hall, 1994.